NUEVA YORK EN MOVIMIENTO

Viajes en taxi, clima y patrones de movilidad

Análisis exploratorio de datos y dashboard operativo
Taxis amarillos de Nueva York · 2024

Alcance	Resultado
Registros fuente TLC	41.169.720
Extracto bruto sin limpiar	600.000 viajes, 50.000 por mes
Conjunto final	576.606 filas y 44 columnas
Periodo analítico	2 de enero a 31 de diciembre de 2024, días UTC completos
Fuentes independientes	NYC TLC y NOAA / NCEI, catalogadas en data.gov

La pregunta central

¿Cómo se relaciona la lluvia indicada con la actividad registrada de los taxis amarillos, la duración de los viajes y las propinas, una vez consideradas las diferencias de calendario y temperatura?

Resultado principal: los tres modelos ajustados no aportan evidencia suficiente al nivel del 5% para afirmar una asociación distinta de cero con el indicador diario de lluvia. Esto no demuestra ausencia de efecto.

Memoria reproducible. Las cifras de volumen son estimaciones ponderadas de viajes que superan los filtros de calidad, no conteos exactos ni medidas de solicitudes de transporte no atendidas.

1. Resumen ejecutivo

El proyecto combina una muestra estratificada de 600.000 registros de taxis con observaciones meteorológicas diarias de LaGuardia. Tras la limpieza, la gestión de cambios de hora y la exclusión de días UTC parciales, se conservan **576.606 viajes** y 365 días. La unión mantiene una fila por viaje y no deja registros sin correspondencia meteorológica.

La duración mediana ponderada es **13,1 minutos**, frente a una media de 16,9. La tarifa base mediana es 14,2 USD y el importe medio registrado es 28,7 USD. La diferencia entre media y mediana muestra la importancia de no describir todo el mercado con un solo promedio.

Resultado diario	Asociación ajustada con lluvia	IC del 95%	p Holm
Volumen diario estimado	2,58 %	[-0,36; 5,61]	0,258
Duracion media diaria	0,90 %	[-0,42; 2,24]	0,364
Propina diaria sobre tarifa (tarjeta)	0,07 puntos porcentuales	[-0,04; 0,18]	0,364

Los intervalos contienen cero. Las estimaciones puntuales son positivas, pero no justifican afirmar que la lluvia aumente de forma demostrada el volumen, la duración o las propinas. Los intervalos son puntuales; la corrección de Holm se aplica a los tres p-valores.

La lectura exige prudencia: al excluir los cinco días más influyentes, un intervalo exploratorio deja de contener cero; el modelo con volumen del día anterior estima una asociación menor. Esta sensibilidad impide presentar una conclusión categórica sobre la lluvia.

Aplicación práctica

Usar el dashboard para identificar cuándo y dónde se concentra la actividad, comparar perfiles horarios y comprobar si una diferencia aparente se mantiene al seleccionar otro mes o borough. Cualquier decisión operativa basada específicamente en lluvia necesitaría datos horarios y validación adicional.

2. Objetivos, preguntas e hipótesis

Objetivo general. Describir la movilidad registrada de los taxis amarillos y examinar su asociación con el contexto meteorológico mediante un proceso trazable de limpieza, análisis y visualización.

Pregunta	Indicador	Hipótesis nula
¿Varía la actividad con lluvia?	Viajes válidos diarios estimados	Coeficiente del indicador de lluvia igual a cero en el modelo logarítmico de volumen.
¿Varía la duración?	Duración media diaria ponderada	Coeficiente de lluvia igual a cero, ajustando también por distancia media.
¿Varían las propinas?	100 × suma de propinas / suma de tarifa base en pagos con tarjeta	Coeficiente de lluvia igual a cero, en puntos porcentuales.

Objetivos específicos. Detectar incidencias de calidad; armonizar fechas y unidades; describir distribuciones y patrones temporales y territoriales; estimar asociaciones con incertidumbre; construir un dashboard que permita explorar los resultados sin modificar código.

Delimitación. El estudio se refiere a taxis amarillos registrados por TLC, no a Uber, Lyft, taxis verdes o toda la movilidad de Nueva York. El término actividad se refiere a viajes realizados y registrados. No equivale a demanda total ni a número de personas únicas.

Criterio de interpretación. Se informa tamaño de asociación, intervalo y p-valor ajustado. Un resultado no significativo puede reflejar una asociación pequeña, variabilidad o limitaciones de medición; no prueba que el clima sea irrelevante.

3. Fuentes, muestreo y trazabilidad

Fuente 1: NYC Taxi and Limousine Commission. Se descargan los doce archivos mensuales oficiales de 2024, que contienen 41.169.720 registros. Incluyen inicio y fin de viaje, distancia, zonas, tarifa, forma de pago y propinas. El catálogo data.gov identifica el conjunto; la descarga mensual procede de la distribución oficial TLC.

Fuente 2: NOAA / NCEI. Global Surface Summary of the Day, estación LaGuardia 72503014732. Se utiliza 2024 y el primer día de 2025 para cubrir el límite temporal al convertir horas locales a UTC. Temperatura, viento, visibilidad, precipitación e indicadores de fenómenos se integran por día UTC.

Fuente auxiliar. La tabla oficial Taxi Zone Lookup traduce los identificadores de zonas a nombres y boroughs. Pertenece a TLC; no se cuenta como segunda fuente independiente.

Diseño muestral. Se seleccionan 50.000 filas aleatorias sin reemplazo de cada mes antes de limpiar, usando semilla 202400 + número de mes. El extracto bruto de 600.000 registros se incluye íntegro en el repositorio con los valores originales y dos campos de trazabilidad: mes de archivo y fila de origen. Los archivos mensuales completos se pueden volver a descargar con el script.

Ponderación. Para el mes m, cada fila representa N_m / 50.000 registros fuente. Por tanto, el total de viajes válidos se estima como la suma de pesos de los registros conservados. Las medias son sumas ponderadas divididas por la suma de pesos; los cuantiles se obtienen sobre la distribución acumulada ponderada. No se presenta la misma muestra mensual como si todos los meses tuvieran el mismo volumen real.

El manifiesto conserva URL, filas fuente, semilla y SHA-256 por archivo. La muestra bruta facilita una reproducción ligera sin volver a descargar los aproximadamente 41 millones de registros.

4. Calidad de datos y decisiones de limpieza

Se aplican reglas de plausibilidad explícitas y ordenadas. Las incidencias pueden superponerse; las exclusiones adicionales cuentan solamente filas todavía conservadas al aplicar cada regla.

Regla	Incidencias	Exclusiones adicionales
Fecha fuera del mes y ano de origen	2	2
Duracion no positiva, ausente o superior a 180 min	592	592
Distancia no positiva, ausente o superior a 100 millas	11.455	11.270
Tarifa o importe no positivo	10.666	9.789
Propina negativa o ausente	16	0

Regla	Incidencias	Exclusiones adicionales
Velocidad superior a 100 mph	182	137

Además, se excluyen 120 horas locales ambiguas o inexistentes por cambios de hora y 1.484 filas correspondientes a días UTC parciales en los extremos. No se inventan horas para resolver ambigüedades. El conjunto final conserva el 96,10% del extracto inicial.

Variable con ausencias	Ausencias	Porcentaje
propina_pct_tarifa	137.329	23,82%
RatecodeID	52.668	9,13%
passenger_count	52.668	9,13%
store_and_fwd_flag	52.668	9,13%
congestion_surcharge	52.668	9,13%
Airport_fee	52.668	9,13%
precipitacion_mm	6.380	1,11%

Los pasajeros ausentes se conservan como ausentes, porque el análisis no depende de imputarlos. La tasa de propina es deliberadamente nula para pagos que no son con tarjeta. Los códigos NOAA de ausencia se convierten a nulos, nunca a ceros. Las zonas no identificadas se etiquetan como Desconocido.

No se detectan coincidencias exactas de contenido entre las filas válidas muestreadas. Un identificador compuesto por mes de archivo y fila de origen garantiza trazabilidad y unicidad, sin afirmar que TLC publique un ID único del viaje.

5. Integración y transformación

Fechas. Los timestamps TLC se interpretan en America/New_York, con horario de verano. GSOD utiliza el día UTC. Se convierte la hora de recogida a UTC antes de extraer la fecha. Unir directamente la fecha local con el día meteorológico UTC asignaría incorrectamente parte de los viajes nocturnos.

Cardinalidad. La tabla meteorológica tiene una fila por fecha. La unión es muchos-a-uno y se comprueba que no cambie el número de viajes y que no existan correspondencias ausentes. Las tablas de zonas se validan también como muchos-a-uno.

Periodo final. Se conservan 365 días completos, del 2 de enero al 31 de diciembre UTC de 2024. Se excluye el 1 de enero UTC y el 1 de enero de 2025 UTC porque el periodo definido por los archivos de 2024 en hora local no cubre esos días enteros.

Variable derivada	Definición
duracion_min	Diferencia entre fin e inicio, expresada en minutos.
distancia_km	trip_distance × 1,609344.
velocidad_kmh	distancia_km / (duracion_min / 60). Es velocidad media del viaje, no velocidad instantánea.
temperatura_c	(TEMP - 32) × 5/9.

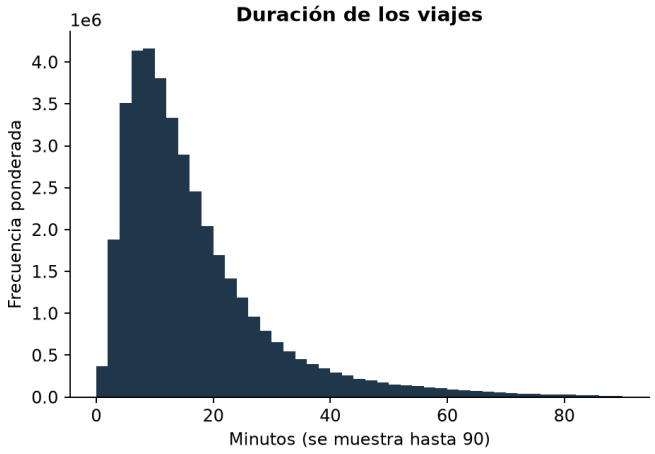
Variable derivada	Definición
viento_kmh	WDSP × 1,852.
precipitacion_mm	PRCP × 25,4; ausencia si código NOAA 99,99 o atributo I.
lluvia_indicada	Segunda posición de FRSHTT igual a 1. Un 0 significa no indicado o no reportado.

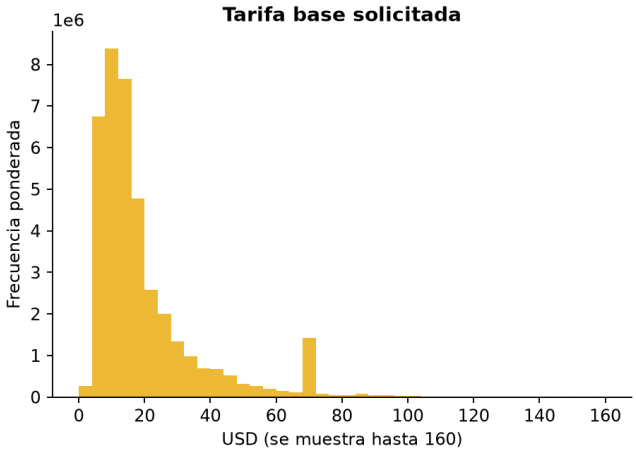
El indicador de lluvia no mide la intensidad y no implica que lloviera durante cada viaje. La precipitación diaria puede incluir parte del día anterior según el periodo de observación de origen. Por eso la asociación se interpreta como contexto diario, no exposición exacta.

La lógica de los cálculos. No se promedian medias de grupos como si todos tuvieran el mismo tamaño. Para duración se suma peso × minutos y se divide por suma de pesos. Para propinas se divide la suma de propinas de tarjeta por la suma de tarifa base de tarjeta. Las hojas Calculos y Razonamiento desarrollan qué pregunta responde cada expresión y qué interpretación sería incorrecta.

Ejemplo didáctico. Dos registros duran 10 y 20 minutos y representan 60 y 80 viajes. La media ponderada es (60 × 10 + 80 × 20) / 140 = 15,71 min; la media simple sería 15 min. Son valores ilustrativos, no registros del dataset.

6. Análisis descriptivo: distribuciones





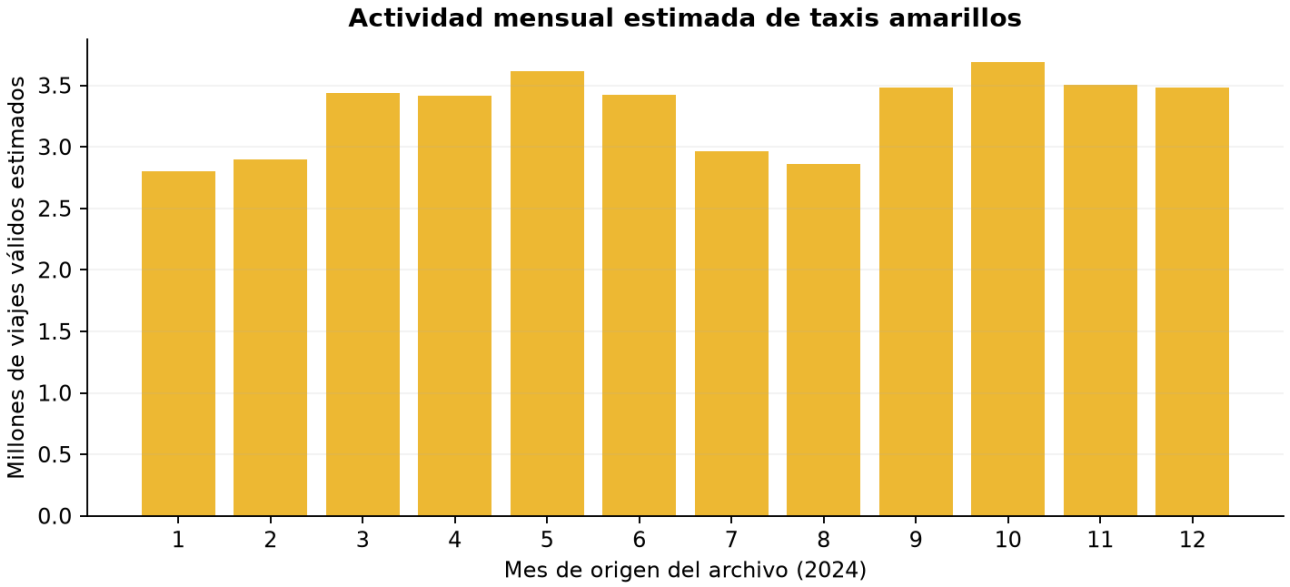
Variable	Media	P25	Mediana	P75	P99
Duración (min)	16,94	8,00	13,10	21,23	70,00
Distancia (km)	5,52	1,72	2,90	5,47	32,27
Tarifa base (USD)	19,82	9,30	14,20	22,60	77,20
Importe total (USD)	28,67	16,00	21,23	30,72	104,88

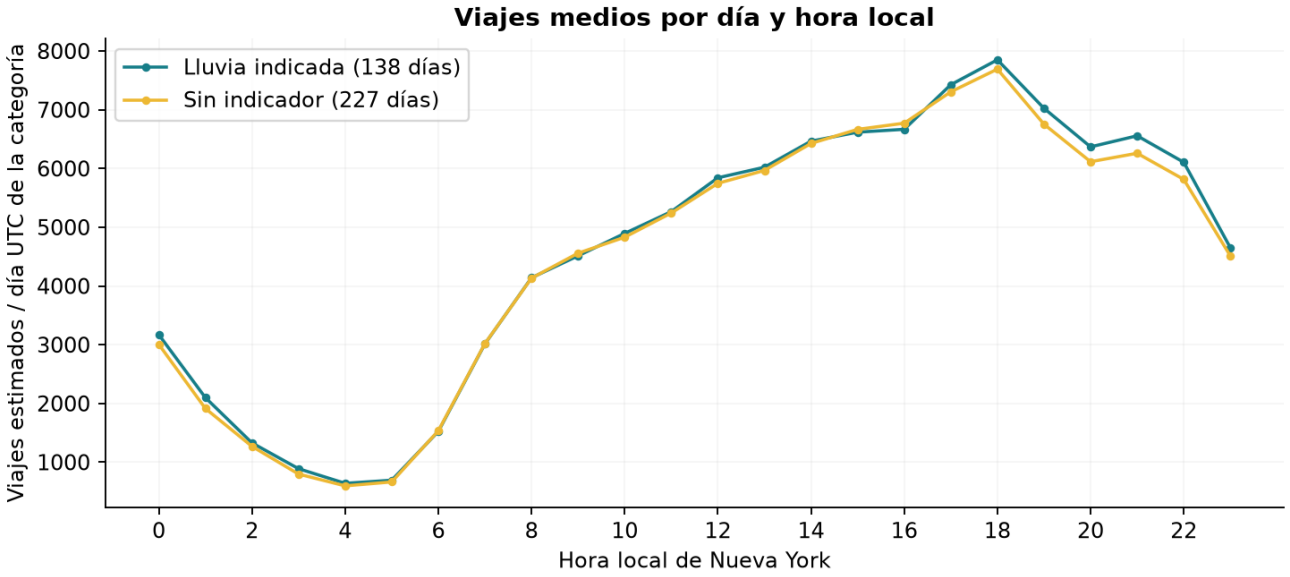
Las distribuciones presentan asimetría a la derecha. La media de duración supera a la mediana; algunos viajes largos elevan el promedio. La distancia mediana es menor que la media, lo que confirma la convivencia de recorridos urbanos cortos con desplazamientos más largos. Los histogramas recortan únicamente la visualización, no eliminan observaciones adicionales del conjunto final.

El 76,1% ponderado de viajes se paga con tarjeta. Para ese subconjunto, la razón agregada entre propinas y tarifa base es 22,1%. Esta razón de sumas no es la media de los porcentajes individuales: las dos medidas responden a preguntas distintas.

La tarifa base excluye conceptos incluidos en el importe total, como recargos y peajes. El importe total registrado no incluye propinas en efectivo. No se lo interpreta como ingreso neto del conductor.

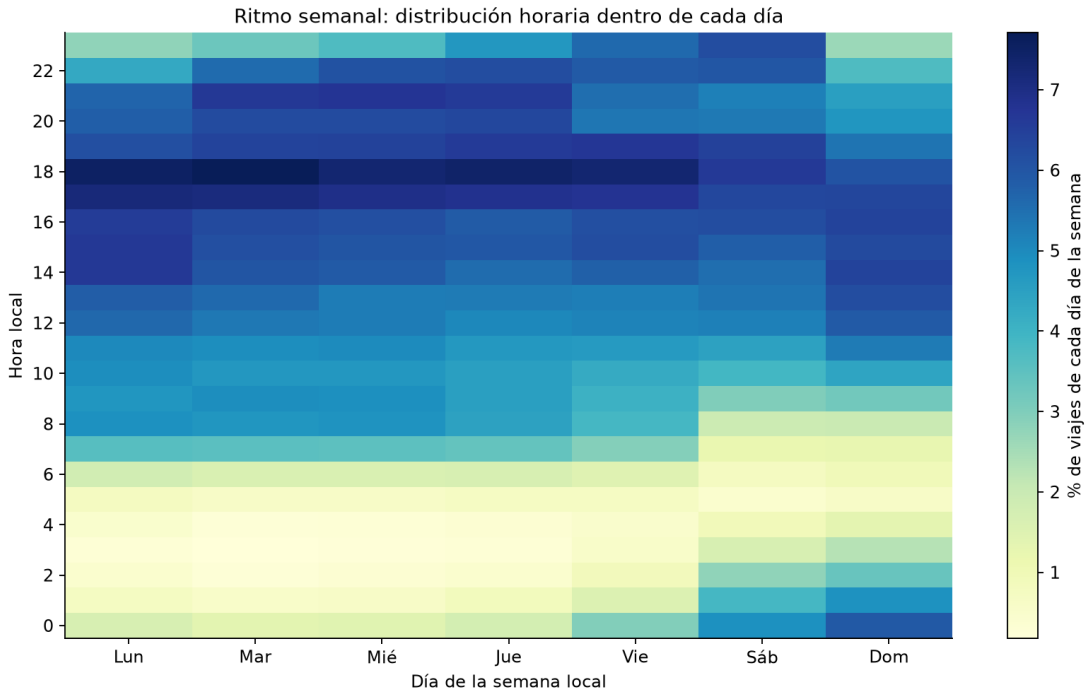
7. Actividad temporal y clima





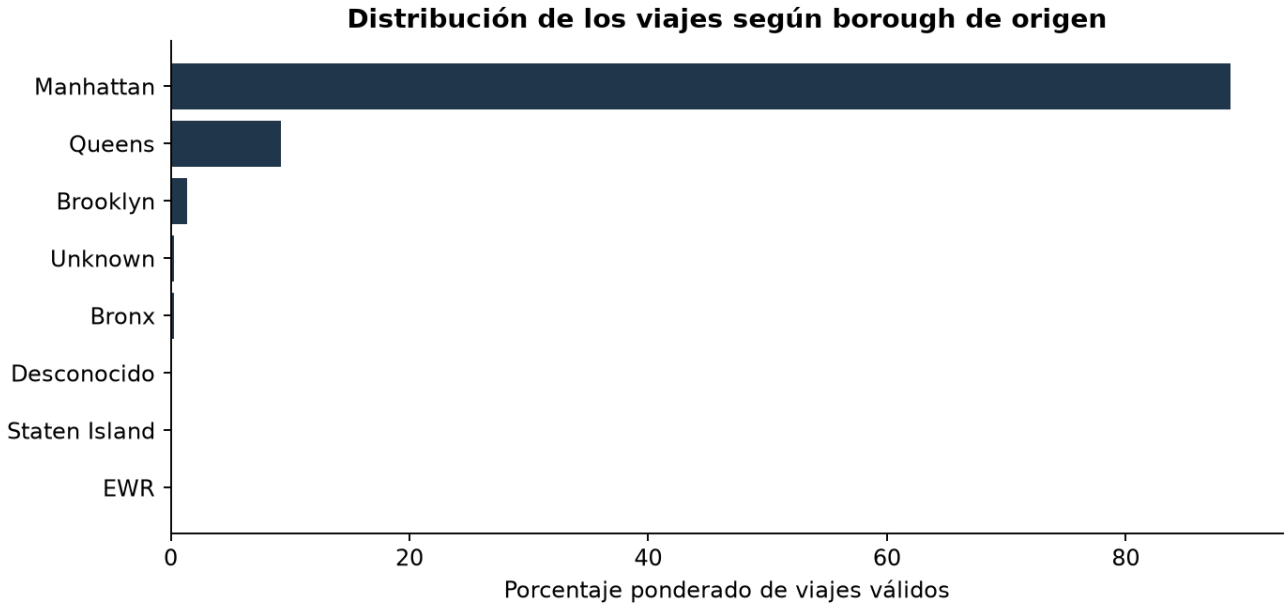
Hay 138 días con lluvia indicada y 227 sin indicador. Para comparar perfiles horarios se divide la actividad estimada de cada categoría por su número de días. Comparar simplemente los totales de ambas categorías produciría una diferencia mecánica por tener distinta cantidad de días.

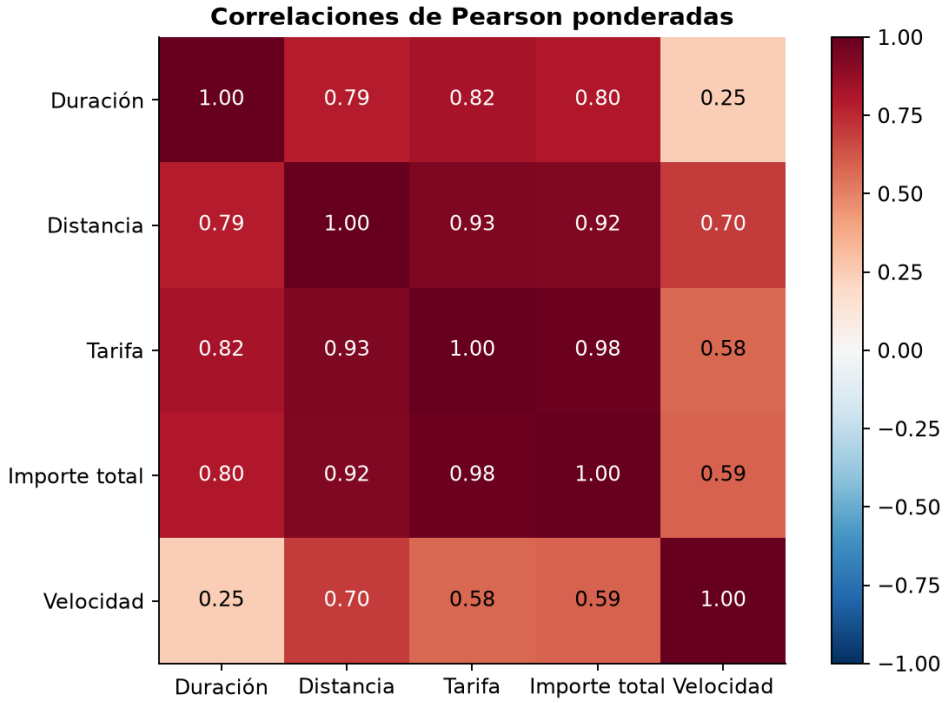
El perfil horario usa la hora local del viaje; el contexto meteorológico se asigna por día UTC. Los perfiles son descriptivos y no están ajustados por mes, día de semana o distribución de zonas. La inferencia ajustada se presenta separadamente.



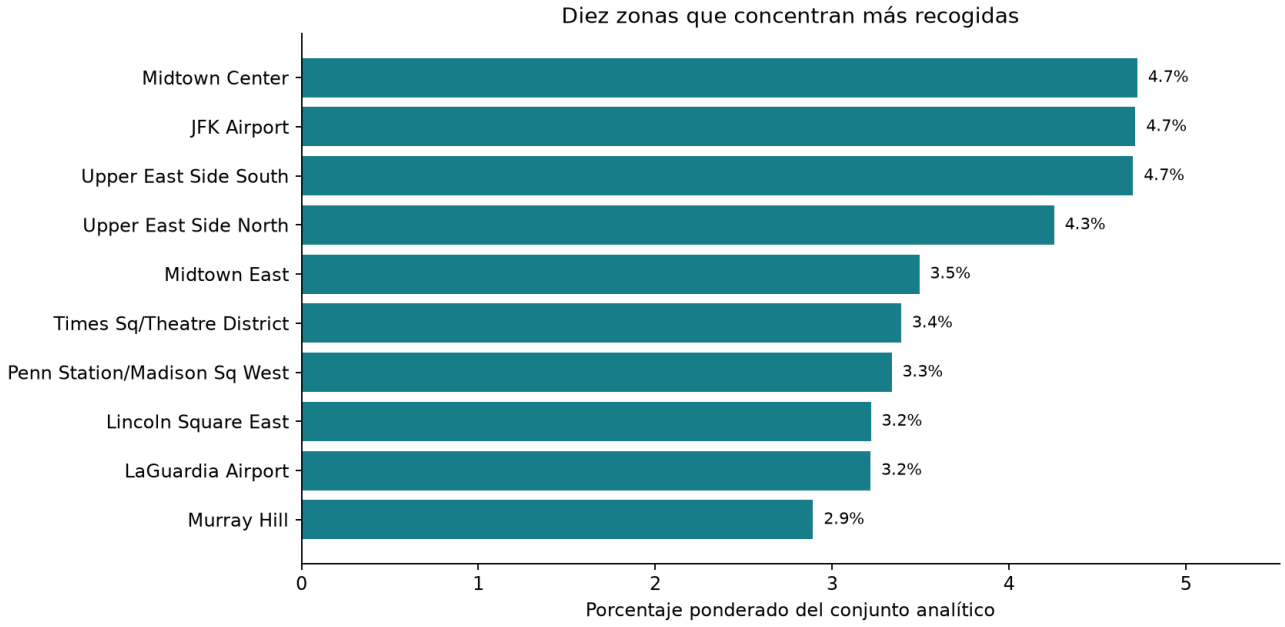
La matriz normaliza cada día semanal al 100%: muestra cómo se reparte su actividad entre horas. El máximo agregado anual está a las 18:00 y el volumen de esa hora es 12,6 veces el de la hora mínima. Esta razón describe el perfil de la muestra ponderada; no prueba falta de taxis ni demanda no atendida.

8. Territorio y relaciones entre variables





La distribución territorial describe el lugar donde empieza el viaje y está ponderada por el diseño muestral. La correlación entre distancia, duración y tarifa es descriptiva: las variables forman parte del propio servicio y de su cálculo tarifario. No demuestra que una intervención sobre una variable produzca el cambio correlacionado en otra.



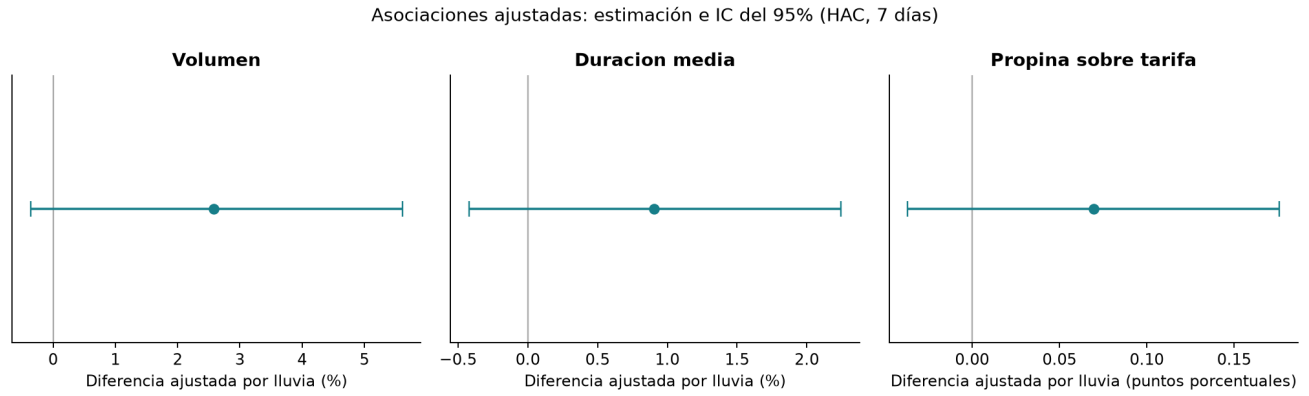
Manhattan concentra el 88,8% ponderado de las recogidas. Las diez zonas principales concentran el 37,9%. Esta concentración sirve para priorizar seguimiento de actividad de taxis amarillos; no permite generalizar sobre todas las modalidades de transporte.

9. Análisis estadístico e incertidumbre

Se construye una tabla de 365 días UTC. Para cada día se estiman volumen, duración media ponderada y proporción agregada de propinas sobre tarifa para tarjeta. Así se evita tratar cientos de miles de viajes como observaciones meteorológicas independientes.

Modelos. Volumen y duración se modelan en logaritmos. Los tres modelos incluyen indicador de lluvia, temperatura, indicador de nieve, efectos de mes y día de la semana UTC. El modelo de duración incorpora también el logaritmo de la distancia media diaria. Son modelos de asociación diaria agregada, no predicciones de cada viaje.

Inferencia. Se utiliza OLS con covarianza HAC, kernel Bartlett y siete retardos, para contemplar heterocedasticidad y dependencia temporal semanal. Se aplica Holm a las tres pruebas sobre lluvia. Los intervalos del 95% son puntuales, no intervalos simultáneos corregidos por Holm.

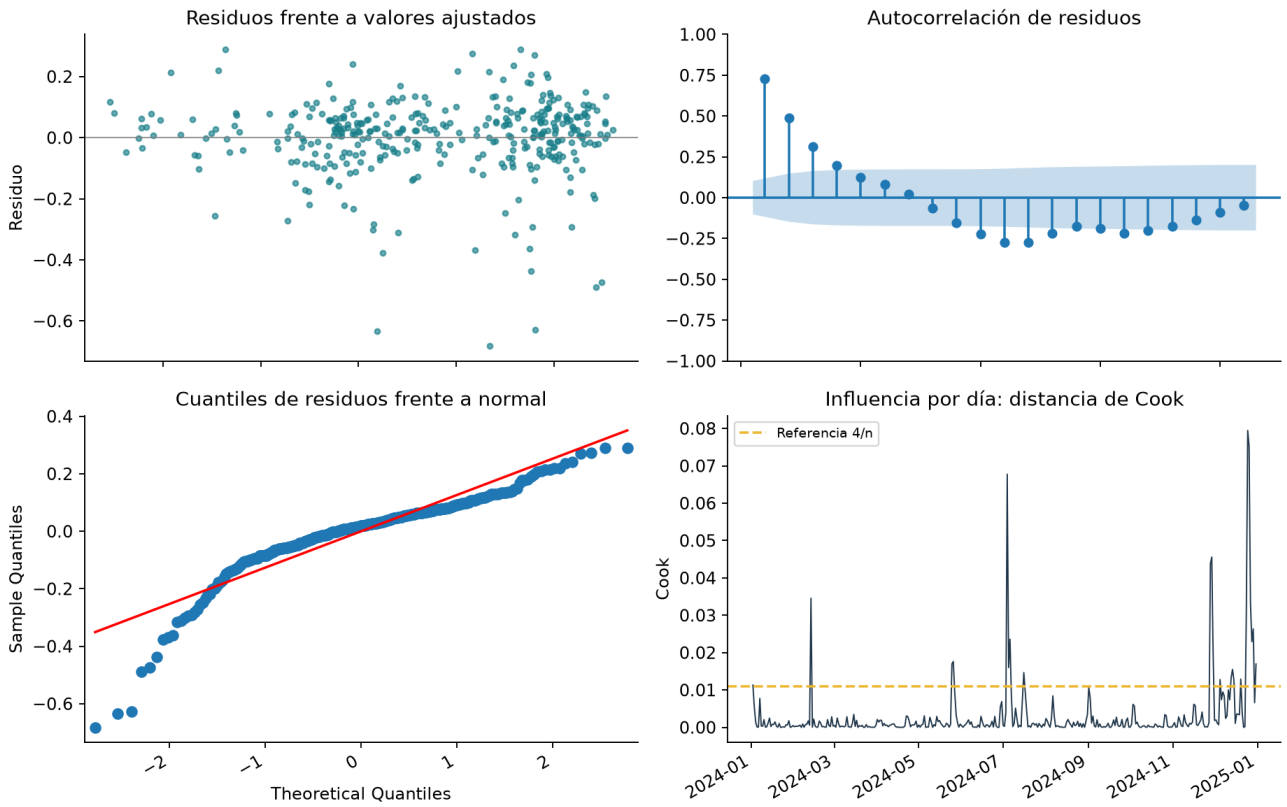


Modelo	Cambio ajustado	IC 95%	p Holm
Volumen diario estimado	2,58 %	[-0,36; 5,61]	0,258
Duracion media diaria	0,90 %	[-0,42; 2,24]	0,364
Propina diaria sobre tarifa (tarjeta)	0,07 puntos porcentuales	[-0,04; 0,18]	0,364

En modelos logarítmicos el cambio se expresa como 100 × [exp(beta) - 1]. Para propina se expresa directamente en puntos porcentuales. Los R^2 son medidas de ajuste dentro de la muestra, no validación predictiva ni prueba causal.

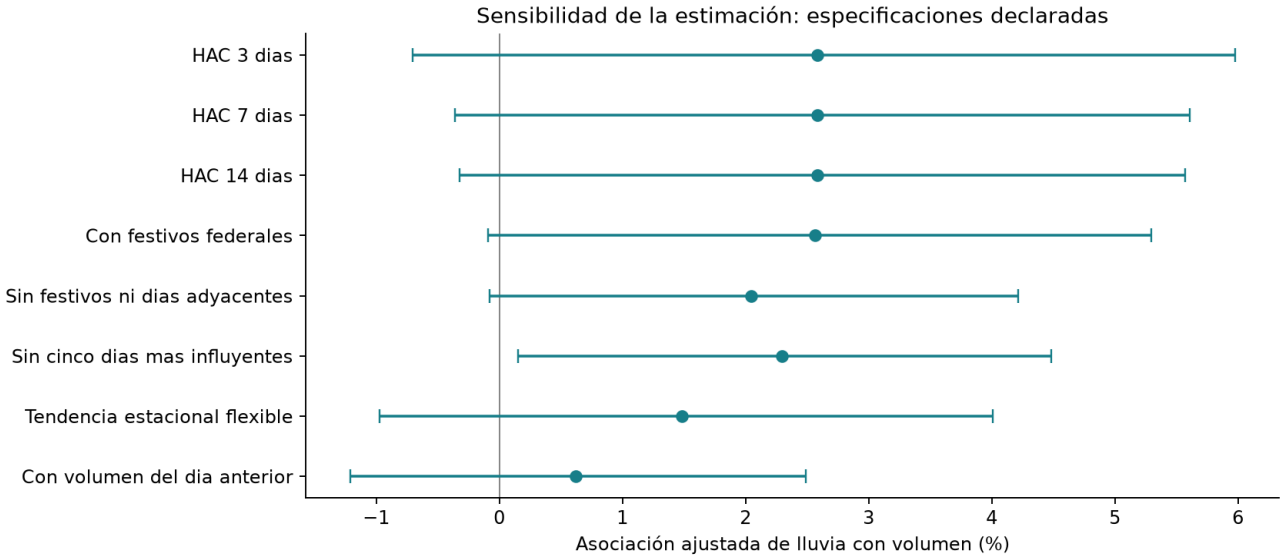
10. Diagnóstico, robustez y razonamiento

Por qué mirar los residuos. Un coeficiente y un p-valor no bastan para juzgar un modelo. La dependencia entre días puede hacer parecer más precisa una estimación, la varianza puede cambiar y algunos días pueden ejercer influencia desproporcionada. Los diagnósticos se usan para descubrir estas limitaciones, no para buscar una especificación con significación.



Modelo	DW	Ljung-Box p7	BP p	R² ajustado
Volumen	0,52	9.79e-70	4.09e-07	0,459
Duracion	1,21	2.42e-12	2.32e-04	0,621
Volumen dinamico	1,84	1.91e-01	4.41e-13	0,802
Propina	1,78	8.55e-02	1.74e-03	0,447

El volumen principal presenta fuerte autocorrelación residual: DW cercano a 0,52 y Ljung-Box p7 muy pequeño. HAC ajusta la covarianza, pero no elimina ese patrón. El modelo dinámico mejora el diagnóstico a siete días (p aproximado 0,19), aunque a catorce días sigue detectándose dependencia y persiste heterocedasticidad. No se presenta como una especificación perfecta.



Especificación exploratoria	Cambio %	IC95%	Días
HAC 3 dias	2,58	[-0,71; 5,98]	365
HAC 7 dias	2,58	[-0,36; 5,61]	365
HAC 14 dias	2,58	[-0,32; 5,57]	365
Con festivos federales	2,57	[-0,09; 5,29]	365
Sin festivos ni dias adyacentes	2,05	[-0,08; 4,21]	334
Sin cinco dias mas influyentes	2,30	[0,15; 4,49]	360
Tendencia estacional flexible	1,49	[-0,97; 4,01]	365
Con volumen del dia anterior	0,62	[-1,21; 2,49]	364

Las ocho especificaciones se informan conjuntamente. Al excluir cinco días elegidos por Cook, el intervalo nominal queda por encima de cero (p exploratorio aproximado 0,036). Ese resultado no sustituye la prueba principal ni demuestra robustez: muestra sensibilidad a días concretos. No se corrigen ni se interpretan confirmatoriamente estas pruebas exploratorias.

La tendencia flexible usa un spline con ocho grados de libertad; el modelo dinámico añade log volumen del día previo. Este último estima una asociación condicionada a actividad previa, una pregunta distinta de la asociación diaria principal. Ambos modelos incluyen un indicador de festivos federales; este es una aproximación de calendario por fecha UTC, no una medición completa de celebraciones locales.

Sensibilidad de limpieza. Al reducir la duración máxima de 180 a 120 minutos, permanecen 576.393 viajes. La asociación puntual entre lluvia y volumen pasa de 2,58% a 2,57%. Esta comparación no revela sensibilidad importante a ese umbral concreto; no prueba robustez ante todos los criterios posibles.

Qué se puede afirmar. Las distribuciones, la concentración territorial y los perfiles temporales están descritos con una muestra trazable y ponderada. Con esta definición diaria de lluvia y estos controles, las tres asociaciones ajustadas no alcanzan significación al 5%.

Qué sigue siendo incierto. El indicador meteorológico es binario y una estación representa toda la ciudad. Puede diluir episodios intensos y locales. Los festivos se incorporan solo en análisis de

sensibilidad. No se incorporan eventos, disponibilidad de taxis, congestión observada ni todas las diferencias de composición de los viajes. El día UTC no coincide con el día civil local.

Muestreo e intervalos. Los volúmenes son estimaciones del subconjunto que supera los filtros; no recuentos exactos. La muestra estratificada no es autoponderada. HAC se aplica a la serie de estimaciones diarias y no sustituye un análisis completo de varianza de un diseño de encuesta complejo. Los intervalos se consideran exploratorios y condicionados a esta construcción.

Causalidad y alcance. No hay asignación aleatoria de clima ni estrategia de identificación causal. No se puede interpretar la regresión como efecto causal. La ausencia de significación no demuestra equivalencia a cero. TLC advierte que los datos proceden de proveedores tecnológicos y no garantiza su exactitud.

Siguiente estudio. Usar meteorología horaria de varias estaciones, incluir festivos y disponibilidad de vehículos, validar con otro año y contrastar la sensibilidad a intensidad y ubicación de la lluvia. Estas ampliaciones mejorarían la medición; no son necesarias para ejecutar el proyecto entregado.

11. Dashboard y aplicación práctica

El archivo Excel incluye Dashboard, Patrones, Robustez, Calculos, Razonamiento, Datos y Metodologia. Razonamiento explica pregunta, procedimiento, motivo y límite de catorce decisiones; Calculos explica cada bloque junto a las fórmulas. La base agrega exhaustivamente todas las filas del conjunto final; no es una muestra adicional. Los pesos no se redondean antes de agregar.

Control o indicador	Funcionamiento
Mes	Selector entre Todos y los doce meses.
Tipo de día	Lunes-viernes o fin de semana según el calendario local; lunes-viernes puede incluir festivos.
Borough de origen	Filtra el territorio de recogida.
Indicador de lluvia	Todos, Lluvia indicada o Sin indicador.
Viajes válidos estimados	Suma de pesos del subconjunto seleccionado.
Duración y distancia medias	Sumas ponderadas divididas por viajes estimados.
Importe medio	Suma ponderada de total_amount / viajes estimados.
Propina / tarifa (tarjeta)	Razón de sumas ponderadas, restringida a tarjeta.
Gráficos	Actividad por hora, mes y borough; duración media por indicador.

Ejemplo de exploración. Seleccionar un mes, Manhattan y lluvia indicada. Observar cómo cambian el volumen, la duración y las propinas; después retirar el filtro de lluvia. Comparar no significa atribuir causalidad: las composiciones de viajes pueden diferir.

Uso operativo prudente. Priorizar el seguimiento de perfiles horarios y zonas con mayor actividad. Utilizar la lluvia como una dimensión de exploración, sin prometer un incremento fijo de demanda o ingresos. Las medias de cada categoría no son efectos ajustados de los modelos.

El contraste por lluvia conserva mes, borough y tipo de día. Patrones y Robustez son anuales. Se verificaron filtros y fórmulas contra sumas independientes. Las nuevas descargas requieren regenerar la base con Python.

12. Reproducción, requisitos y referencias

Entorno. Python, Pandas, NumPy, PyArrow, Matplotlib y Statsmodels. VS Code puede abrir la carpeta y ejecutar los scripts o el notebook. Las versiones utilizadas se registran en el archivo de entorno.

Secuencia. Instalar requirements.txt; ejecutar 01_preparar.py sobre los extractos incluidos; ejecutar 02_analizar.py y 07_profundizar.py; consultar el notebook y abrir el dashboard. 00_descargar.py permite reconstruir el extracto bruto desde los doce archivos oficiales. El PDF se regenera con 03_memoria.py. La reconstrucción del Excel usa el generador JavaScript y la dependencia artifact-tool descrita en el README; el Excel entregado no requiere Python para los filtros.

Criterio de la entrega	Evidencia
Dos fuentes independientes	Extracto TLC y CSV NOAA originales, con enlaces y manifiesto.
Mínimo 50.000 filas y 20 columnas	576.606 filas y 44 columnas tras limpieza y unión.
Transformación y limpieza	Scripts, registro de exclusiones y tabla de ausencias.
Análisis descriptivo y estadístico	Notebook, siete figuras, regresiones y resultados HAC.
Dashboard operativo	Excel con selectores, fórmulas y gráficos.
Informe y README	Esta memoria y documentación en español.
Repositorio GitHub organizado	Carpetas y paquete preparados; la publicación requiere una cuenta GitHub.

TLC en data.gov
https://catalog.data.gov/dataset/2024-yellow-taxi-trip-data

NOAA en data.gov
https://catalog.data.gov/dataset/global-surface-summary-of-the-day-gsod

Distribución y diccionario TLC
https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page

Documentación NOAA GSOD
https://www.ncei.noaa.gov/data/global-summary-of-the-day/doc/readme.txt

Calendario federal 2024: publicación oficial CBP
https://content.govdelivery.com/accounts/USDHSCBP/bulletins/38366be

Statsmodels: covarianza robusta HAC
https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.OLSResults.get_robustcov_results.html

Atribución: datos TLC conforme a los términos de NYC Open Data y datos NOAA con la atribución a NOAA/NCEI. La tabla de zonas procede de TLC. No se presenta el trabajo como producto oficial de estos organismos.